M01_BatchGD_Regression
Họ tên: Trần Chí Vỹ
MSS5V: 3123580065
Tên học phần: Học sâu
Lớp môn học: DDU1231

Link docs:
https://docs.google.com/document/d/1ybMSPsKPHOmtms1rmkdvDu6NnICU-FXdc76A-0XuZhE/edit?hl=vi&tab=t.0

Phần A: Neuron Không có hàm kích hoạt

Câu A1 - Forward pass

công thức:

$\hat{y}_i = w \cdot x_i + b$

$e_i = \hat{y}_i - y_i$

Mẫu 1:

- $x_1 = 1, y_1 = 3$
- $\hat{y}_1 = 0 \cdot 1 + 0 = 0$
- $e_1 = \hat{y}_1 - y_1 = 0 - 3 = -3$
- $e_1^2 = (-3)^2 = 9$

Mẫu 2:

- $x_2 = 2, y_2 = 5$
- $\hat{y}_2 = 0 \cdot 2 + 0 = 0$
- $e_2 = \hat{y}_2 - y_2 = 0 - 5 = -5$
- $e_2^2 = (-5)^2 = 25$

Mẫu 3

- $x_3 = 3, y_3 = 7$
- $\hat{y}_3 = 0 \cdot 3 + 0 = 0$
- $e_3 = \hat{y}_3 - y_3 = 0 - 7 = -7$
- $e_3^2 = (-7)^2 = 49$

Bảng forward pass

i	x_i	y_i	w	b	$\hat{y}_i$	e_i	e_i^2
1	1	3	0	0	0	-3	9

2	2	5	0	0	0	-5	25
3	3	7	0	0	0	-7	49

Câu A2 - Tính Loss

Công thức
cho bài toán này

$$MSE = \frac{1}{3}\sum_{i=1}^{3} e_i^2$$

Thế số:

$$\sum e_i^2 = 9 + 25 + 49 = 83$$

$$MSE = \frac{1}{3} \cdot 83 = \frac{83}{3} \approx 27.6667$$

Vậy Loss tại epoch 0 của neuron không hàm kích hoạt là:

$$L = MSE = 27.6667$$

Câu A3 - Tính gradient Batch Gradient Descent

Công thức gradient:

1. $$\frac{\partial L}{\partial w} = \frac{2}{3}\sum_{i=1}^{3} e_i \cdot x_i$$
2. $$\frac{\partial L}{\partial b} = \frac{2}{3}\sum_{i=1}^{3} e_i$$

Tính từng giá trị:

i	e_i	x_i	$e_i \cdot x_i$
1	-3	1	-3
2	-5	2	-10
3	-7	3	-21

Tổng:

- $\sum e_i = -3 + (-5) + (-7) = -15$
- $\sum e_i \cdot x_i = -3 + (-10) + (-21) = -34$

thế vào công thức

- $\frac{\partial L}{\partial w} = \frac{2}{3} \cdot (-34) = -\frac{68}{3} \approx -22.6667$
- $\frac{\partial L}{\partial b} = \frac{2}{3} \cdot (-15) = -\frac{30}{3} = -10$

Vậy gradient là:

- $\frac{\partial L}{\partial w} = -22.6667$
- $\frac{\partial L}{\partial b} = -10$

Câu A4 - Cập nhật tham số

Công thức cập nhật

- $w^{(1)} = w^{(0)} - \eta \cdot \frac{\partial L}{\partial w}$
- $b^{(1)} = b^{(0)} - \eta \cdot \frac{\partial L}{\partial b}$

Với $\eta = 0.01$, $w^{(0)} = 0$, $b^{(0)} = 0$

Cập nhật w

- $w^{(1)} = 0 - 0.01 \cdot (-22.6667)$
- $w^{(1)} = 0 + 0.226667$
- $w^{(1)} = 0.226667$

Cập nhật b

- $b^{(1)} = 0 - 0.01 \cdot (-10)$
- $b^{(1)} = 0.1$

Bảng cập nhật:

tham số	giá trị cũ	gradient	learning rate	giá trị mới
w	0	-22.6667	η	0.226667
b	0	-10	η	0.1

Kết quả sau 1 lần cập nhật

$w^{(1)} = 0.226667, b^{(1)} = 0.1$

Phần B - Neuron có hàm kích hoạt Sigmoid

Câu B1- Foward pass

Mẫu 1

$$x_1 = 1, y_1 = 3$$
$$z_1 = w \cdot x_1 + b = 0 \cdot 1 + 0 = 0$$
$$\hat{y}_1 = \sigma(0) = \frac{1}{1+e^0} = \frac{1}{1+1} = \frac{1}{2} = 0.5$$
$$e_1 = \hat{y}_1 - y_1 = 0.5 - 3 = -2.5$$

Mẫu 2:

$$x_2 = 2, y_2 = 5$$
$$z_2 = w \cdot x_2 + b = 0 \cdot 2 + 0 = 0$$
$$\hat{y}_2 = \sigma(0) = \frac{1}{1+e^0} = \frac{1}{1+1} = \frac{1}{2} = 0.5$$
$$e_2 = \hat{y}_2 - y_2 = 0.5 - 5 = -4.5$$

Mẫu 3

$$x_3 = 3, y_3 = 7$$
$$z_3 = w \cdot x_3 + b = 0 \cdot 3 + 0 = 0$$
$$\hat{y}_3 = \sigma(0) = \frac{1}{1+e^0} = \frac{1}{1+1} = \frac{1}{2} = 0.5$$
$$e_3 = \hat{y}_3 - y_3 = 0.5 - 7 = -6.5$$

Bảng forward pass có hàm kích hoạt sigmoid

i	x_i	y_i	z_i	$\hat{y}_i$	e_i	e_i^2
1	1	3	0.5	0	-2.5	6.25
2	2	5	0.5	0	-4.5	20.25
3	3	7	0.5	0	-6.5	42.25

Tính Loss của trường hợp Sigmoid:

$$e_1^2 = (-2.5)^2 = 6.25$$
$$e_2^2 = (-4.5)^2 = 20.25$$
$$e_3^2 = (-6.5)^2 = 42.25$$
$$\sum e_i^2 = 6.25 + 20.25 + 42.25 = 68.75$$
$$MSE = \frac{1}{3} \cdot 68.75 = 22.9167$$

Câu B2 - Đạo hàm của hàm Sigmoid

$$\sigma'(z) = \sigma(z) \cdot (1 - \sigma(z))$$

Vì $\hat{y} = \sigma(z)$, nên:

$$\sigma'(z_i) = \hat{y}_i \cdot (1 - \hat{y}_i)$$

Tại epoch 0, $z_i = 0$ nên $\hat{y}_i = 0.5$

Do đó:

$$\hat{y}_i \cdot (1 - \hat{y}_i) = 0.5 \cdot (1 - 0.5) = 0.5 \cdot 0.5 = 0.25$$

Câu B3 - Tính Gradient bằng chain rule

Công thức

$$\frac{\partial L}{\partial w} = \frac{2}{3} \sum_{i=1}^{3} e_i \cdot \hat{y}_i \cdot (1 - \hat{y}_i) \cdot x_i$$

$$\frac{\partial L}{\partial b} = \frac{2}{3}\sum_{i=1}^{3} e_i \cdot \hat{y}_i \cdot (1-\hat{y}_i)$$

Mẫu 1

$$e_1 = -2.5$$
$$\hat{y}_1 \cdot (1-\hat{y}_1) = 0.25$$
$$e_1 \cdot \hat{y}_1 \cdot (1-\hat{y}_1) \cdot x_1 = -0.625$$ (vì x đầu tiên là 1 nên nhân với 1 cũng ra chính nó)

Mẫu 2

$$e_2 = -4.5$$
$$\hat{y}_2 \cdot (1-\hat{y}_2) = 0.25$$
$$e_2 \cdot \hat{y}_2 \cdot (1-\hat{y}_2) = -4.5 \cdot 0.25 = -1.125$$
$$e_2 \cdot \hat{y}_2 \cdot (1-\hat{y}_2) \cdot x_2 = -1.125 \cdot 2 = -2.25$$

Mẫu 3

$$e_3 = -6.5$$
$$\hat{y}_3 \cdot (1-\hat{y}_3) = 0.25$$
$$e_3 \cdot \hat{y}_3 \cdot (1-\hat{y}_3) = -6.5 \cdot 0.25 = -1.625$$
$$e_3 \cdot \hat{y}_3 \cdot (1-\hat{y}_3) \cdot x_3 = -6.5 \cdot 0.25 \cdot 3 = -4.875$$

thế vào công thức

$$\sum e_i y_i (1-y_i) = -0.625 + (-1.125) + (-1.625) = -3.375$$
$$\sum e_i y_i (1-y_i) x_i = -0.625 + (-2.25) + (-4.875) = -7.75$$
$$\frac{\partial L}{\partial w} = \frac{2}{3} \cdot (-7.75) = -\frac{15.5}{3} \approx -5.1667$$
$$\frac{\partial L}{\partial b} = \frac{2}{3} \cdot (-3.375) = -\frac{6.75}{3} = -2.25$$

Bảng gradient bằng chain rule:

i	e_i	$\hat{y}_i(1-\hat{y}_i)$	$e_i \cdot \hat{y}_i(1-\hat{y}_i)$	x_i	$e_i \cdot \hat{y}_i(1-\hat{y}_i) \cdot x_i$
1	-2.5	0.25	-0.625	1	-0.625
2	-4.5	0.25	-1.125	2	-2.25
3	-6.5	0.25	-1.625	3	-4.875

Câu B4 - Cập nhật tham số

công thức

$$w^{(1)} = w^{(0)} - \eta \cdot \frac{\partial L}{\partial w}$$
$$b^{(1)} = b^{(0)} - \eta \cdot \frac{\partial L}{\partial b}$$

với $\eta = 0.01$, $w^{(0)} = 0$, $b^{(0)} = 0$
cập nhật w

- $w^{(1)} = 0 - 0.01 \cdot (-5.1667)$
- $w^{(1)} = 0 + 0.051667$
- $w^{(1)} = 0.051667$

cập nhật b

$b^{(1)} = 0 - 0.01 \cdot (-2.25)$

$b^{(1)} = 0 + 0.0225$

$b^{(1)} = 0.0225$

kết quả sau 1 lần cập nhật

$w^{(1)} = 0.051667, b^{(1)} = 0.0225$

Bảng kết quả cập nhật

tham số	giá trị cũ	gradient	learning rate	giá trị mới
w	0	-5.1667	0.01	0.051667
b	0	-2.25	0.01	0.0225

Phần C - Câu hỏi nhận xét

Câu 1: so sánh biểu thức gradient của 2 trường hợp

trong trường hợp neuron không hàm kích hoạt, mô hình có dạng:

$\hat{y} = w \cdot x + b$

gradient của hàm MSE theo w và b là:

$$\frac{\partial L}{\partial w} = \frac{2}{3} \sum e_i \cdot x_i$$

$$\frac{\partial L}{\partial b} = \frac{2}{3} \sum e_i$$

Trong trường hợp này, $\hat{y}$ phụ thuộc trực tiếp vào $z = w \cdot x + b$ và không có hàm phi tuyến ở giữa. Vì vậy đạo hàm của $\hat{y}$ theo z bằng 1. Gradient chỉ phụ thuộc vào sai số e_i và dữ liệu đầu vào x_i

trong trường hợp neuron có hàm kích hoạt sigmoid, mô hình có dạng

$z = w \cdot x + b$

$\hat{y} = \sigma(z)$

Gradient của hàm MSE là:

$$\frac{\partial L}{\partial w} = \frac{2}{3} \sum e_i \cdot \hat{y}_i \cdot (1 - \hat{y}_i) \cdot x_i$$

$$\frac{\partial L}{\partial b} = \frac{2}{3} \sum e_i \cdot \hat{y}_i \cdot (1 - \hat{y}_i)$$

So với trường hợp không hàm kích hoạt, gradient của sigmoid có thêm thừa số $\hat{y}_i \cdot (1 - \hat{y}_i)$. Thừa số này xuất hiện do áp dụng chain rule khi đạo hàm qua hàm kích hoạt sigmoid. Cụ thể:

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial w}$$

Trong đó:

$\frac{\partial L}{\partial \hat{y}}$ tạo ra thành phần của sai số e_i

$$\frac{\partial \hat{y}}{\partial z} = \sigma'(z) = \hat{y}_i \cdot (1 - \hat{y}_i)$$

$$\frac{\partial z}{\partial w} = x_i$$

Vì vậy, gradient trong sigmoid không chỉ phụ thuộc vào sai số của x_i mà còn phụ thuộc vào độ dốc của hàm sigmoid tại điểm z_i

Câu 2: vì sao gradient trong những trường hợp sigmoid nhỏ hơn

Gradient trong trường hợp sigmoid nhỏ hơn vì đạo hàm của sigmoid bị chặn trên. Ta có:

$$\sigma'(z) = \sigma(z) \cdot (1 - \sigma(z))$$

Giá trị lớn nhất của $\sigma'(z)$ là 0.25, đạt được khi $\sigma(z) = 0.5$. Nghĩa là trong mọi trường hợp:

$$0 < \sigma'(z) \leq 0.25$$

Ở bài này, tại epoch 0 ta có $z_i = 0$ nên $\hat{y}_i = 0.5$ và:

$$\sigma'(0) = 0.5 \cdot (1 - 0.5) = 0.25$$

Do đó, các thành phần gradient của sigmoid bị nhân thêm 0.25. Nếu so sánh trực tiếp

Neuron không hàm kích hoạt

$$\sum e_i \cdot x_i = -34$$

Sigmoid:

$$\sum e_i \cdot \hat{y}_i \cdot (1 - \hat{y}_i) \cdot x_i = -7.75$$

Giá trị -7.75 có độ lớn nhỏ hơn nhiều so với -34.

Tương tự:

Neuron không có hàm kích hoạt:

$$\sum e_i = -15$$

Sigmoid:

$$\sum e_i \cdot \hat{y}_i \cdot (1 - \hat{y}_i) = -3.375$$

Vì gradient nhỏ hơn, bước cập nhật tham số cũng nhỏ hơn. Kết quả sau 1 lần cập nhật:

Không hàm kích hoạt:

$$w^{(1)} = 0.226667, b^{(1)} = 0.1$$

Có sigmoid:

$w^{(1)} = 0.051667, b^{(1)} = 0.0225$

Như vậy, sigmoid làm giảm tốc độ thay đổi của tham số vì nó nén giá trị đầu ra vào khoảng (0, 1) và đạo hàm của nó không vượt quá 0.25.

Câu 3: trường hợp nào hội tụ nhanh hơn? giải thích

Với dữ liệu của bài toán này, neuron không hàm kích hoạt sẽ hội tụ nhanh hơn.

Lý do thứ nhất là dữ liệu có mối tuyến tính rất rõ:

- Khi $x = 1$ thì $y = 3$
- Khi $x = 2$ thì $y = 5$
- Khi $x = 3$ thì $y = 7$

Ta thấy y tăng 2 đơn vị khi x tăng 1. Do đó dữ liệu phù hợp với đường thẳng: $y = 2x + 1$

Neuron không hàm kích hoạt có mô hình:

$\hat{y} = w \cdot x + b$

Mô hình này có thể biểu diễn trực tiếp quan hệ $y = 2x + 1$ bằng cách học $w = 2$ và $b = 1$. Vì mô hình đúng dạng với dữ liệu nên quá trình học sẽ đi theo hướng giảm loss trực tiếp và hiệu quả.

Lý do thứ hai là gradient của neuron không hàm kích hoạt lớn hơn 0.

Epoch 0:

Không hàm kích hoạt:

$\frac{\partial L}{\partial w} = -22.6667, \frac{\partial L}{\partial b} = -10$

Có sigmoid:

$\frac{\partial L}{\partial w} = -5.1667, \frac{\partial L}{\partial b} = -2.25$

Với cùng learning raterate $\eta = 0.01$, bước cập nhật của trường hợp không hàm kích hoạt lớn hơn:

$\Delta w = 0.226667, \Delta b = 0.1$

Trong khi sigmoid chỉ cập nhật:

$\Delta w = 0.051667, \Delta b = 0.0225$. Vì bước cập nhật của sigmoid nhỏ hơn nên nó tiến về nghiệm chậm hơn.

Lý do thứ ba là sigmoid có đầu ra từ 0 tới 1 trong khi giá trị y của bài toán là 3, 5, 7.

Dù đầu vào thế nào cũng có kết quả trong khoảng đó nên sigmoid không phù hợp để hồi quy trực tiếp các giá trị lớn hơn 1, vì nó sẽ bị giới hạn đầu ra và loss không thể giảm tốt như mô hình tuyến tính

Kết luận: Trong bài toán này, Neuron không hàm kích hoạt hội tụ nhanh hơn và phù hợp hơn

Câu 4: dữ liệu bài toán này có phù hợp sigmoid không? vì sao

Như câu 3, dữ liệu bài toán không phù hợp với sigmoid làm đầu ra trực tiếp cho bài toán hồi quy.

Ngoài lý do đã giải thích ở câu 3 thì bổ sung như sau:

- Kết quả sau khi cho qua hàm sigmoid sẽ dự đoán thấp hơn nhiều so với thực tế y.

- Ngoài ra thì sigmoid phù hợp hơn với bài toán phân loại nhị phân, trong đó đầu ra cần nằm trong khoảng 0 tới 1 để biểu diễn xác suất. Ví dụ như xác suất sống sót hay mắc bệnh. Còn với bài toán hồi quy có dữ liệu đầu ra liên tục và có giá trị lớn hơn 1 nên mô hình tuyến tính không hàm kích hoạt phù hợp hơn.
- Nếu muốn dùng sigmoid trong bài toán hồi quy thì ta cần biến đổi dữ liệu y về khoảng 0 tới 1, ví dụ dùng chuẩn hóa min-max. Tuy nhiên, sau khi dự đoán xong cần biến đổi ngược lại về thang đo ban đầu, nếu không chuẩn hóa y lại thì việc dùng sigmoid là vô dụng.

Kết luận: Dữ liệu bài toán này không phù hợp với sigmoid đầu ra trực tiếp. Mô hình phù hợp hơn là Neuron không hàm kích hoạt vì nó có thể học được quan hệ tuyến tính $y = 2x + 1$.