

TITANIC

MACHINE LEARNING FROM DISASTER

Xây dựng quy trình dự đoán khả năng sống sót bằng PyTorch MLP

TRẦN CHÍ VỸ

MSSV 3123580065 · Bài thực hành tuần 2

TÓM TẮT

Báo cáo trình bày một pipeline học máy có thể tái lập cho bài toán Titanic của Kaggle. Quy trình bao gồm phân tích dữ liệu, xây dựng đặc trưng, tiền xử lý không rò rỉ, huấn luyện mạng MLP bằng PyTorch, điều chỉnh siêu tham số, đánh giá đa chỉ số và xuất submission. Các đặc trưng từ danh xưng, quy mô gia đình, trạng thái trẻ em/người mẹ, cabin và tiền tố vé bổ sung ngữ nghĩa cho 12 cột gốc. Bộ tiền xử lý chỉ được fit trên train split; mô hình dùng BCEWithLogitsLoss, AdamW, class weight, dropout, giảm learning rate và early stopping. Baseline nhẹ dùng để kiểm tra dữ liệu đạt Accuracy 79.78% và F1 70.97% trên 178 mẫu validation.

ĐÓNG GÓP CHÍNH

- Pipeline split trước, fit preprocessing sau để chống leakage.
- Feature engineering có giải thích nghiệp vụ.
- MLP có regularization, early stopping và tuning theo F1.
- Lưu đầy đủ model, params, metrics, ảnh và submission.

Từ khóa: Titanic · binary classification · PyTorch · MLP · reproducibility

Bài toán, dữ liệu và quan sát EDA

1. GIỚI THIỆU

Cuộc thi Titanic yêu cầu dự đoán liệu một hành khách có sống sót hay không từ thông tin nhân khẩu, hạng vé, người thân đi cùng và hành trình. Đây là bài toán phù hợp để minh họa toàn bộ vòng đời dự án máy học: hiểu dữ liệu, xác định nguồn sai lệch, xây dựng đặc trưng, chọn mô hình, đánh giá và đóng gói kết quả. Mục tiêu của bài không chỉ là tạo file dự đoán, mà còn tổ chức thí nghiệm để có thể chạy lại.

2. DỮ LIỆU

Tập train có 891 hành khách và 12 cột; tập test có 418 hành khách và không chứa nhãn Survived. Tỷ lệ sống sót trong train là 38,4%, tạo mất cân bằng vừa phải. Age thiếu khoảng 19,9%, Cabin thiếu 77,1%, Embarked thiếu 2 giá trị; test còn thiếu một Fare.

NHÂN KHẨU	Sex · Age	One-hot · median · scale
KINH TẾ	Pclass · Fare	One-hot · median · scale
GIA ĐÌNH	SibSp · Parch	FamilySize · IsAlone
HÀNH TRÌNH	Embarked · Ticket	One-hot · prefix
VỊ TRÍ	Cabin	CabinKnown · Deck

3. EDA — PHÁT HIỆN CHÍNH

Nữ có tỷ lệ sống sót khoảng 74,2%, nam khoảng 18,9%. Tỷ lệ sống sót giảm từ 63,0% ở Pclass 1 xuống 24,2% ở Pclass 3. Hai tín hiệu này phù hợp bối cảnh ưu tiên phụ nữ/trẻ em và lợi thế tiếp cận xuồng cứu sinh của hành khách hạng cao.

Từ feature engineering đến tensor

3.1. FEATURE ENGINEERING

Title được trích từ Name và gom thành Mr, Mrs, Miss, Master, Rare. FamilySize bằng SibSp + Parch + 1; IsAlone đánh dấu hành khách đi một mình. IsChild và IsMother biểu diễn nhóm ưu tiên. FarePerPerson chuẩn hóa giá vé theo quy mô nhóm. CabinKnown và Deck khai thác trạng thái cabin; TicketPrefix biểu diễn nhóm vé. Mọi biến được tạo mà không sử dụng nhãn.

TITLE	Tuổi · giới · địa vị	FAMILY	Quy mô nhóm đi cùng
PRIORITY	Trẻ em · người mẹ	ECONOMIC	Giá vé tương đối
LOCATION	Cabin và boong tàu	TICKET	Nhóm vé và hành trình

3.2. CHỐNG RÒ RỈ DỮ LIỆU

Dữ liệu được chia train/validation 80/20 và stratify theo Survived. Numeric pipeline điền median rồi StandardScaler. Categorical pipeline điền mode rồi OneHotEncoder với handle_unknown=ignore. ColumnTransformer chỉ fit trên train split, sau đó mới transform validation/test. Nhờ vậy, thống kê của validation không ảnh hưởng quá trình học.

SPLIT → FIT TRAIN → TRANSFORM VAL/TEST → TENSOR

seed 42 · stratified split · reusable preprocessor

MLP gọn, regularization có kiểm soát

4.1. KIẾN TRÚC MLP

Mạng gồm hai lớp ẩn, Batch Normalization, ReLU và Dropout; đầu ra là một logit. BCEWithLogitsLoss ổn định số học hơn sigmoid + binary cross-entropy tách rời. pos_weight bù mất cân bằng lớp. AdamW tối ưu trọng số; ReduceLROnPlateau giảm learning rate khi F1 không cải thiện; early stopping khôi phục state tốt nhất.



4.2. KHÔNG GIAN TUNING

CONFIG	H1	H2	DROP	LR	BATCH
SMALL	16	8	0.10	1e-3	32
MEDIUM	32	16	0.20	1e-3	32
WIDE	64	32	0.30	5e-4	32
COMPACT	24	12	0.15	2e-3	64


4.3. TIÊU CHÍ CHỌN

Mô hình được chọn theo validation F1; ROC-AUC và Accuracy dùng để phá hòa. Seed 42 được cố định cho Python, NumPy, PyTorch và DataLoader. Sau lựa chọn, bộ tiền xử lý được fit lại trên toàn bộ train và mô hình cuối học đúng số epoch tốt nhất.

Artifacts: params.json · tuning_results.csv · preprocessor.joblib · best_model.pt · images/

Đánh giá, submission và hướng phát triển

5. KẾT QUẢ SANITY CHECK



Baseline logistic kiểm tra dữ liệu trên 178 mẫu validation có TN=98, FP=12, FN=24, TP=44. Precision cao hơn recall cho thấy vẫn còn bỏ sót hành khách sống sót; MLP dùng class weight và chọn theo F1 để xử lý điểm yếu này.

6. SUBMISSION VÀ TÁI LẬP

Submission đi kèm có đúng 418 dòng, PassengerId duy nhất và Survived chỉ nhận 0/1. Baseline dự đoán 156 hành khách sống sót. Khi chạy notebook, file sẽ được tạo lại từ MLP cuối cùng. Toàn bộ model, preprocessing, cấu hình, tuning result và hình được lưu trong experiments/titanic_mlp_chivy_v1/.

7. KẾT LUẬN

Bài thực hành xây dựng được pipeline đầy đủ, kiểm soát data leakage và có khả năng tái lập. Feature engineering chuyển dữ liệu hành khách thành tín hiệu phù hợp; MLP được regularize và tuning có tiêu chí rõ ràng. Hướng phát triển gồm stratified K-fold, hiệu chỉnh threshold theo F1, so sánh với Logistic Regression/Random Forest/gradient boosting và ensemble sau khi kiểm chứng chéo.

TÀI LIỆU THAM KHẢO

- [1] Kaggle — Titanic: Machine Learning from Disaster.
- [2] PyTorch Documentation — torch.nn, optimizers, reproducibility.
- [3] Scikit-learn Documentation — preprocessing and metrics.
- [4] Titanic PyTorch notebooks s1 và s2 — tài liệu thực hành nội bộ.